Тестовое задание на Junior Аналитик данных
Файзуллин Б.Д.

Блок 1. Математика

Задание 1: Фермер

На ферме содержатся шесть разных видов животных, и каждый раз, когда фермер заходит в сарай, он видит одно случайное животное. За день фермер заходит в сарай 6 раз.
Каково математическое ожидание количества разных видов животных, которые фермер увидит за день?
Ответ округлить до сотых, например: 4,12

Решение: Вероятность **не** встретить первое животное = 5/6
Для шести визитов вероятность не встретить первое животное будет = (5/6)^6
Тогда найдём обратную вероятность = 1 - (5/6)^6
Так как у нас 6 видов животных, и для каждого из них вероятность «быть увиденным» одинакова, мы просто складываем эти вероятности =
6*(1 - (5/6)^6) = 3.99
Ответ: 3,99

Задание 2: Кулинарное соревнование

В конкурсе участвуют 80 шеф-поваров с уникальными уровнями мастерства. В первом этапе судьи случайным образом распределяют их по парам (в любом состязании двух шефов выигрывает тот, у кого выше уровень мастерства). На втором этапе шефы снова случайно образуют пары для финального раунда (пары могут повториться). Победную награду получают те, кто выиграл в обоих этапах.
Каково математическое ожидание числа победителей?
Ответ округлить до десятых, например: 33,5

Решение: Отсортируем шефов и тогда индекс шефа будет равен его мастерству.
Тогда вероятность победы шефа$_k$ = (k-1)/79
Вероятность двух побед = ((k-1)/79)^2
тогда для каждого шефа нам нужно подставить под k число от 1 до 80 и сложить получившиеся вероятности = 26.84 (округлил до 2 знаков после запятой)
Также я воспользовался формулой
Ответ: 26,84

Задание 3: Одинокая дорога

На пустынном шоссе вероятность появления автомобиля за 30-минутный период составляет 0.95.
Какова вероятность его появления за 10 минут? А за 27 минут?
Ответ дать в процентах, округлив до десятых через точку с запятой, например: 42,7; 95,0

Решение: Сначала найдём обрутную вероятность = 0.05

Чтобы это произошло, нужно, чтобы на каждых из трёх временных отрезков по 10 минут не было машин, то есть обозначим отсутствие машины за 10 минут за P₁₀
$P_{10}^3 = 0.05$
$1 - P_{10} = 0.632$
для 27 минут те же размышления, только сначала найду для 3 минут и возведу в 9 степень:
$P_3^{10} = 0.05$
$1 - P_{27}^9 = 0,933$
Ответ: 63,2; 93,3

Блок 2: Python

Задание 1: Изоморфизмы

Реализовать функцию (или тело функции), которая проверяет на изоморфность два слова. Пояснение: строки s и t называются изоморфными, если все вхождения каждого символа строки s можно последовательно заменить другим символом и получить строку t. Порядок символов при этом должен сохраняться, а замена — быть уникальной. Так, два разных символа строки s нельзя заменить одним и тем же символом из строки t, а вот одинаковые символы в строке s должны заменяться одним и тем же символом.

```
# Пример:
s = 'paper'
t = 'title'
print(is_isomorphic(s, t))
# Вывод:
True
```

Оценить оптимальность решения по времени и памяти и прикрепить текст кода.

Решение:

```
def isomorph(s: str, t: str) -> bool:
    if len(s) != len(t):
        return False
    else:
        mapping_s_to_t = {}
        used_characters_t = set()

        for char_s, char_t in zip(s, t):
            if char_s in mapping_s_to_t:
                if mapping_s_to_t[char_s] != char_t:
                    return False
            else:
                if char_t in used_characters_t:
                    return False

                mapping_s_to_t[char_s] = char_t
                used_characters_t.add(char_t)
    return True
print(isomorph("egg", "add"))  # True
print(isomorph("foo", "bar"))  # False
```

Решение 2:

```
def is_isomorphic(s, t):
    return len(set(s)) == len(set(t)) == len(set(zip(s, t)))
print(is_isomorphic("egg", "add"))  # True
print(is_isomorphic("foo", "bar"))  # False
```

Критерий	Классический dict	Лаконичный set
Big O (Время)	O(N)	O(N)
Big O (Память)	O(K) (эффективнее)	O(N) или O(K)
Скорость (фактич.)	Быстрее на длинных строках	Быстрее пишется (одна строка)
Читаемость	Понятна логика шагов	Требует знания zip и set

Задание 2: Натуральная последовательность

Реализовать функцию (или тело функции), которая находит единственное отсутствующее число из последовательности натуральных чисел 1,2,…,n.

```
# Пример:
nums = [1, 2, 3, 4, 5, 6, 8, 9, 10, 11]
print(missing_number(nums))
# Вывод:
7
```

Оценить оптимальность решения по времени и памяти и прикрепить текст кода.

```
def missing_number(nums):
    n = len(nums) + 1
    expected_sum = n * (n + 1) // 2
    actual_sum = sum(nums)
    return expected_sum - actual_sum
nums = [1, 2, 3, 4, 5, 6, 8, 9, 10, 11]
print(missing_number(nums))  # 7
```

по времени: O(N)

по памяти: O(1)

Задание 3: Факторизация

Реализовать функцию (или тело функции), которая при введении натурального числа n разбивает его на простые множители (представить его в виде простых чисел).

```
# Пример:
n = 56
print(prime_factors(n))
# Вывод:
[2, 2, 2, 7]
```

Оценить оптимальность решения по времени и памяти и прикрепить текст кода.

```
def primal_number(n):
    a = []
    i = 2
    while i * i <= n:
        if n % i == 0:
            a.append(i)
            n //= i
        else:
            i += 1
    if n > 1:
        a.append(n)
    return a
print(primal_number(60))
```

Сложность O($\sqrt{N}$)

Блок 3: SQL

Задание 1: Абитуриенты

Есть таблица examination с двумя полями: id (id абитуриента), scores (кол-во набранных баллов дополнительного вступительного испытания от 0 до 100).

Требуется реализовать запрос, который создаёт колонку с позицией абитуриента в общем рейтинге.

Решение:

```
SELECT
   id,
   scores,
   RANK() OVER (ORDER BY scores DESC) AS position
FROM examination;
```

Задание 2: FULL JOIN

Представьте две таблицы: первая содержит 30 строк, а вторая — 20 строк. Мы выполняем операцию FULL JOIN между ними.

Какой диапазон возможного количества строк может быть в результирующей таблице, если учесть, что ключи для соединения могут быть как полностью совпадающими, так и абсолютно уникальными?

Ответ:

Для **FULL JOIN** (полного внешнего объединения) результат включает в себя:

1. Строки, которые нашли пару (совпадение ключей).
2. Строки из первой таблицы, которым не досталось пары (дополняются значениями NULL).
3. Строки из второй таблицы, которым не досталось пары (дополняются значениями NULL).

Для минимального количества строк все 20 строк второй таблицы есть в первой, тогда ответ 30
Для максимального количества строк 20 и 30 строк не пересекаются ответ будет 50

Задание 3: Покупки

```
create table account
(
   id integer, -- ID счета
```

```
    client_id integer, -- ID клиента
    open_dt date, -- дата открытия счета
    close_dt date -- дата закрытия счета
)

create table transaction
(
    id integer,  -- ID транзакции
    account_id integer,  -- ID счета
    transaction_date date,  -- дата транзакции
    amount numeric(10,2), -- сумма транзакции
    type varchar(3) -- тип транзакции
)
```

Вывести ID клиентов, которые за последний месяц по всем своим счетам совершили покупок меньше, чем на 5000 рублей.

Без использования подзапросов и оконных функций.

Решение:

```
SELECT
    a.client_id
FROM account a
JOIN transaction t ON a.id = t.account_id
WHERE t.transaction_date >= CURRENT_DATE - INTERVAL '1 month'
  AND t.type = 'purchase' -- Предполагаем, что тип покупки обозначается так
GROUP BY a.client_id
HAVING SUM(t.amount) < 5000;
```

Блок 4: Статистика и АБ-тесты

Задание 1: Воодушевленное руководство

Вы – аналитик компании Самокат (сервис по доставке продуктов на дом).

Команда решила протестировать гениальную идею замены транспортного средства доставщиков и провели АБ эксперимент в небольшом городке РФ. Результаты превзошли все ожидания: время доставки значимо снизилось в несколько раз! Руководству не терпится применить изменения по всей стране.

Делаем? Выберите все верные утверждения:

1. Делаем. Только применяем изменения в таком же масштабе (количество транспортных средств с изменением), как в городе, где проводили тест.
2. Тест нерепрезентативен, поэтому результаты применять по всей стране нельзя.
3. Тест репрезентативен относительно своей генеральной совокупности: таких же небольших городов, можем применять только в подобных городах.
4. Наличие эффекта подтвердило потенциал идеи, поэтому сразу применять по всем городам не будем, но можем провести эксперимент в других городах.

Ответ: 2, 4

Задание 2: Основной показатель в статистике

Что такое p-value в статистическом тестировании? Выберите одно верное утверждение:

1. Вероятность, что нулевая гипотеза верна.
2. Вероятность наблюдения такого или более экстремального результата при условии, что нулевая гипотеза верна.
3. Значение уровня значимости, при котором отвергается нулевая гипотеза.
4. Среднее значение выборки.

Ответ: 2

Задание 3: Параметрический тест

Вам необходимо провести аб-тестирование, целевая метрика - среднее число уникальных покупок на пользователя. Размер выборки велик (более 5 млн наблюдений в группах теста и контроля), значительные выбросы в выборках отсутствуют.

Можем ли мы применить t-критерий Стьюдента для проверки гипотезы о неравенстве средних в тестовой и контрольной группах при условии, что распределение уникальных покупок является логнормальным?

Ответ: Да, можем. Благодаря центральной предельной теореме и отсутствию выбросов.

Блок 5: ML Base

Задание 1: Пони тоже кони

Вас просят разработать модель, классифицирующую лошадок и пони. Вместо разработки вы нашли на GitHub две интересные модели и после прогона на ваших данных одна из них показала ROC-AUC=0.7, а другая ROC-AUC=0.1. Какую модель вы возьмете для дальнейшей работы и что будете с ней делать?

Ответ написать развернутый, но кратко, например: "первую, отниму от метрики 0.1 для корректировки точности"

Ответ: Я возьму модель с ROC-AUC = 0.1, но изменю результат на противоположный.

Задание 2: Ручной счёт ROC_AUC

Классификатор выдал следующие прогнозируемые метки класса и вероятности принадлежности к классу "1". На основе полученных данных рассчитайте метрику ROC_AUC. Тезисно описать ход решения.

Истинная метка класса	Порог классификации (0.6)	Оценка вероятности
1	1	0.95
0	1	0.9
1	1	0.85
0	1	0.8
1	1	0.75
1	1	0.7
1	1	0.65
1	1	0.6
0	0	0.55
0	0	0.5
0	0	0.45
1	0	0.4
0	0	0.35
0	0	0.3
0	0	0.25

Решение:

Посчитаю количество «0» и «1».

- **1-я единица** (0.95): ниже неё **8** нулей (все нули в списке).
- **2-я единица** (0.85): ниже неё **7** нулей (все, кроме нуля на 0.90).
- **3-я единица** (0.75): ниже неё **6** нулей.
- **4-я единица** (0.70): ниже неё **6** нулей.
- **5-я единица** (0.65): ниже неё **6** нулей.
- **6-я единица** (0.60): ниже неё **6** нулей.
- **7-я единица** (0.40): ниже неё **3** нуля (те, что на 0.35, 0.30 и 0.25).

Сложу все полученные числа: Sum = 8+7+6+6+6+6+3 = 42
Количество пар нулей и единиц = 7 * 8 = 56
Тогда AUC = 42/56 = 0,75

Задание 3: Ручной счёт корреляции

Рассчитайте линейную корреляцию Пирсона, на основе данных.

Какой вывод можно сделать на основе полученного результата? Можно ли утверждать, что существует причинно-следственная связь между количеством чашек кофе, выпитых студентами в течение экзаменационного дня, и их итоговым баллом за экзамен?

Число выпитых чашек кофе	**Балл за экзамен**
1	85
1	88
2	79
2	81
2	84
2	65
3	67
3	58
3	76
4	49

Решение:

n = 10 (количество студентов)

Количество чашек (X) = 23

Баллы (Y) = 732

$$r = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2 \sum_{i=1}^{n}(y_i - \overline{y})}}$$

или, если упростить для нашей задачи,

$$r = \frac{n\sum XY - (\sum X)(\sum Y)}{\sqrt{[n\sum X^2 - (\sum X)^2][n\sum Y^2 - (\sum Y)^2]}}$$

r ≈ - 0.83

Коэффициент -0.83 говорит о сильной отрицательной линейной связи. Это значит, что в данной выборке с увеличением количества выпитых чашек кофе баллы за экзамен имеют четкую тенденцию к снижению.